

Intern-S2 原版 vs 训练版 · 对比接口说明

给在服务器上做对比界面（UI）的同学。两个模型通过同一个地址提供服务，**一次只开一个**：先开原版问一遍，切换到训练版，再问同样的问题，最后把两边答案放在一起比。

- 负责人：Chunqian（Topic 6 / Task 1.3）
- 更新：2026-10-10（加了第三个模型 S2-6datasets，见第一节末尾）

一、两个模型是什么

	原版	训练版
简称（工具和答案文件里用）	intern-s2-base	intern-s2-medlora
是什么	老师提供的 Intern-S2-Preview，没有训练过	在原版上做了医学微调，就是交给世龙部署的那个
服务器目录（只读）	/home/ubuntu/Large-Model-Service-Interns2/models/Intern-S2-Preview	/home/ubuntu/Large-Model-Service-Interns2/models/Intern-S2-Preview-MedLoRA
大小	35B 参数，混合专家结构（每次约激活 3B），73 GB	同左

训练版用了什么数据训练

只用了两份英文数据，合计 5,219 条：

数据	条数	内容	许可
SLAKE 训练集（英文部分）	4,919	医学影像问答：CT、MRI、X 光等图片加短问答，例如「这是什么检查？」「病灶在哪个器官？」	CC BY 4.0
PubMedQA（专家标注集的训练半边）	300	纯文字题：给一段论文摘要，回答 yes / no / maybe，三类各 100 条。用来教模型在证据不足时敢说「不确定」	MIT

没有用来训练的数据：CheXpert Plus、VQA-RAD、PathVQA、MedQA、PneumoniaMNIST，以及 SLAKE 测试集、PubMedQA 的另一半。这些都**只用来考试**。

怎么训练的

- **方法**：LoRA（只训练一小块「补丁」，原模型参数不动）。
 - rank 16、alpha 32、dropout 0.05；
 - 只挂在语言部分的注意力层和共享专家上，可训练参数 1,917 万，占全部参数的 0.054%；
 - 看图部分（视觉编码器）不训练。
- **参数**：学习率 1e-4，3 轮，有效 batch 16，图片上限 512×512 像素，随机种子 42，训练时**关闭思考模式**。
- **耗时**：4 张 RTX 5090，978 步，1 小时 58 分。

- **交付**：训练好的补丁合并进原模型，成为一个完整模型（世龙的推理环境加载不了单独的补丁）。
- 训练代码： `train/interns2/train_lora.py` ； 合并代码： `train/interns2/merge_lora.py` 。

第三个模型：S2-6datasets (2026-10-10 起可用)

	S2-6datasets
简称	intern-s2-6ds
服务器目录 (只读)	/home/ubuntu/chunqian/merged/interns2_6ds
训练数据	上面两份，再加四个数据集的 训练部分 ：VQA-RAD 734、PathVQA 5,000、MedQA 3,000、PneumoniaMNIST 2,000，合计 15,953 条
训练方法	和训练版完全一样，只换了数据
已知表现	SLAKE、PubMedQA、TextVQA、MMBench 四项和训练版基本一样（差别在一两道题以内）；VQA-RAD 等四项的结果待补

切换： `bash train/interns2/compare_serve.sh switch six` 。上面「训练版」指的仍是交给世龙的那个（S2-2datasets）。

二、已知表现（先看这个，对比时心里有数）

以下全部是**关闭思考模式**时的成绩，训练版就是上面这一个模型（种子 42），每项只测过一次。

测试	原版	训练版	说明
SLAKE 是非题	84.4	94.5	主任务，训练用的同一套题的测试部分
SLAKE 开放题（完全答对）	67.1	86.4	
PubMedQA macro-F1	61.8	67.3	「不确定」答对：7 → 22（共 55 题）
VQA-RAD 是非题	80.5	85.3	另一套放射科题，没训练过，说明不是背题
TextVQA（看图读字）	88.8	86.7	略降
MMBench（通用看图选择题）	93.6	94.0	基本不变
PathVQA 是非题（病理切片）	80.1	76.8	下降，而且变得爱答「no」
MedQA（医师考试文字题）	85.0	83.6	小降
胸片描述：有病的片子被写成「正常」	29.2%	68.5% ⚠️	CheXpert Plus 2,733 张有病的成人胸片

一句话：

- 训练版**医学短答明显更好**，也更敢说「不确定」；
- 但**让它描述胸片时，很容易把有病写成正常**，这一点比原版差很多。

对比时，挑几道「描述这张胸片」的题，能看到这个差别。

⚠️ 两个模型都只能用于研究和演示，不能用于临床判断。

三、使用流程

通知世龙 → 开原版 → 问一批题 → 切到训练版 → 问同一批题 → 合并 → 关服务 → 告诉世龙

服务器上 (ubuntu 账号) :

```
cd /home/ubuntu/chunqian/MedLoRA

# 0. 先通知世龙：要用 0-3 号卡，请他停掉他的服务（端口 23333）。
# 他的服务开着时，下面的脚本会拒绝启动，不会去停他的服务。

# 1. 开原版（约 3-6 分钟）
bash train/interns2/compare_serve.sh switch base

# 2. 提问（单问，或批量跑一个问题文件）
conda activate /home/ubuntu/chunqian/envs/s2train
python scripts/compare_ask.py ask "What modality is used in this image?" --image /path/to/image.png
python scripts/compare_ask.py batch questions.jsonl

# 3. 切到训练版，用同一个问题文件再跑一遍
bash train/interns2/compare_serve.sh switch final
python scripts/compare_ask.py batch questions.jsonl
# （想再比 S2-6datasets: switch six, 再 batch 一遍; merge 时把三个答案文件都列出来）

# 4. 合并两边答案（按题目对齐）
python scripts/compare_ask.py merge
# → outputs/compare/compare.jsonl
# 每行: {"id", "question", "image", "intern-s2-base": "...", "intern-s2-medlora": "..."}

# 5. 用完关掉，告诉世龙可以开回他的服务
bash train/interns2/compare_serve.sh stop
```

随时查看状态: `bash train/interns2/compare_serve.sh status`

问题文件 `questions.jsonl` 每行一道题, `id` 不能重复, `image` 可以不写:

```
{"id": "q1", "question": "Is there any abnormality in this chest X-ray? Answer yes or no."}
{"id": "q2", "question": "Describe this chest X-ray in two or three sentences, including any abnormal findings.", "image": "/home/ubuntu/xxx/chest.png"}
```

- 批量中途断了，重跑同一条命令会**接着跑**，已答过的题不重问。
- 答案存在 `outputs/compare/answers_<模型名>.jsonl`。

四、给 UI 直接调用的接口

UI 也可以不经过上面的小工具，直接调接口。接口是 **OpenAI 兼容格式**，由 LMDeploy 提供。

项目	值
地址（在主机上）	<code>http://127.0.0.1:23334/v1</code>
地址（在 user0 等容器里）	<code>http://172.17.0.1:23334/v1</code>
查当前是哪个模型	GET <code>/v1/models</code> ，返回的 <code>data[0].id</code> 是 模型目录路径 ：结尾是 <code>Intern-S2-Preview</code> 就是原版，结尾是 <code>Intern-S2-Preview-MedLoRA</code> 就是训练版，结尾是 <code>interns2_6ds</code> 就是 S2-6datasets
提问	POST <code>/v1/chat/completions</code>
鉴权	不需要

必须带的设置

1. **关闭思考模式**：请求里加 `"chat_template_kwargs": {"enable_thinking": false}`。
 - 不关的话，模型会先写一大段推理，慢很多，而且和我们测出的成绩不是同一种设置。
2. **temperature: 0**：同一道题每次答案基本不变，两边对比才公平。
3. **model 原样填** `/v1/models` 返回的 **id**（一个目录路径）。UI 按路径结尾显示成「原版」或「训练版」。

为什么不给服务起个短名字：服务的启动参数和我们测成绩时保持完全一致，一个都不改，这样对比看到的回答就是测出来的那个模型的真实表现。

文字题 (curl)

```
# 原版时 model 填下面这个路径；训练版时换成 .../Intern-S2-Preview-MedLoRA（以 /v1/models 返回的为准）
curl -s http://127.0.0.1:23334/v1/chat/completions -H "Content-Type: application/json" -d '{
  "model": "/home/ubuntu/Large-Model-Service-Interns2/models/Intern-S2-Preview",
  "messages": [{"role": "user", "content": "What is pneumothorax? Answer in one sentence."}],
  "temperature": 0, "max_tokens": 512,
  "chat_template_kwargs": {"enable_thinking": false}
}'
```

看图题 (Python, 需要 requests 和 Pillow)

图片以 base64 data URL 发送。建议和我们测试时一样，先等比缩到不超过 512×28×28 像素（约 40 万像素）：

```
import base64, io, math, requests
from PIL import Image

BASE = "http://127.0.0.1:23334/v1"
model = requests.get(f"{BASE}/models", timeout=10).json()[0]["id"]

img = Image.open("chest.png").convert("RGB")
w, h = img.size
limit = 512 * 28 * 28
if w * h > limit:
    s = math.sqrt(limit / (w * h))
    img = img.resize((int(w * s), int(h * s)), Image.LANCZOS)
buf = io.BytesIO(); img.save(buf, format="PNG")
url = "data:image/png;base64," + base64.b64encode(buf.getvalue()).decode()

r = requests.post(f"{BASE}/chat/completions", timeout=600, json={
    "model": model,
    "messages": [{"role": "user", "content": [
        {"type": "image_url", "image_url": {"url": url}},
        {"type": "text", "text": "Describe this chest X-ray in two or three sentences."}]}],
    "temperature": 0, "max_tokens": 512,
    "chat_template_kwargs": {"enable_thinking": False},
}).json()
print(model, r["choices"][0]["message"]["content"])
```

UI 要处理的几种情况

情况	现象	建议 UI 显示
正在切换模型	连接被拒绝, 或 <code>/v1/models</code> 超时	「模型切换中, 请稍等几分钟」
两个模型都没开	同上	提示运行 <code>compare_serve.sh status</code> 查看
回答被截断	<code>finish_reason</code> 为 <code>"length"</code>	标注「回答过长被截断」, 可以调大 <code>max_tokens</code>
回答里出现 <code><think>...</think></code>	忘了关思考模式	检查请求有没有带 <code>enable_thinking: false</code>

- 每次提问都**先查** `/v1/models` , **按返回的路径记下是哪个模型**, 再存答案。不要靠「我以为现在开的是哪个」, 免得两边搞混。
- 速度参考: 短答几秒, 描述类一二十秒, 图片大、回答长会更久。超时建议设 600 秒。

五、规矩（一定要遵守）

1. 一次只开一个模型，用完就 `stop`。0-3 号卡是和世龙共用的，6、7 号卡不能用。
2. 不要自己去停世龙的服务，先找他本人。切换脚本也不会替你停。
3. 两个模型目录只读：不改、不复制、不移动。
4. 演示只用公开图片，例如 SLAKE、VQA-RAD 的图片，或网上公开的教学图片。不要用 CheXpert Plus 的病人片子，那是受控数据，提问记录和截图也不能带出服务器。
5. 不要把接口开放到服务器外面。

六、相关文件

文件	作用
<code>train/interns2/compare_serve.sh</code>	切换 / 查看 / 关闭对比服务
<code>train/interns2/serve.sh</code>	起 LMDeploy 服务（切换脚本内部调用）
<code>scripts/compare_ask.py</code>	单问、批量提问、合并答案
<code>scripts/mock_api_server.py</code>	假接口，不占显卡，用来离线测试 UI： <code>python scripts/mock_api_server.py --port 8765 --model-name /x/models/Intern-S2-Preview</code> （假装是原版；换成 <code>.../Intern-S2-Preview-MedLoRA</code> 就是假装训练版）
<code>docs/cards/MODEL_CARD.md</code>	模型卡（训练细节、全部成绩）
<code>docs/cards/DATA_CARD.md</code>	数据卡（每个数据集的来源和许可）