模型与补丁位置

Models and adapter locations

用途：医学问答与看图回答的研究试用。 已完成训练和主要测试；本说明不代表服务当前在线。路径来自项目记录，执行前需在主机核对文件。无需等待 CheXbert 复核即可试问，但成人胸片描述的判断仍待复核。

原版基座 / Base model（只读）

```
/home/ubuntu/Large-Model-Service-Interns2/models/Intern-S2-Preview
```

训练补丁 / Trained adapters（以下是完整权重文件路径）

版本	补丁权重文件	训练方式
A42，默认试用	`/home/ubuntu/chunqian/MedLoRA/outputs/interns2_s2a/adapter_model.safetensors`	八数据集问答微调，种子 42
A43，重复实验	`/home/ubuntu/chunqian/MedLoRA/outputs/interns2_s2a_s43/adapter_model.safetensors`	同样问答微调，种子 43
B42	`/home/ubuntu/chunqian/MedLoRA/outputs/interns2_s2b/adapter_model.safetensors`	知识预训练后问答微调，种子 42
B43	`/home/ubuntu/chunqian/MedLoRA/outputs/interns2_s2b_s43/adapter_model.safetensors`	同一个预训练补丁后问答微调，种子 43
C42	`/home/ubuntu/chunqian/MedLoRA/outputs/interns2_s3c/adapter_model.safetensors`	B42 后再做答案与解析微调
cpt1，仅预训练对照	`/home/ubuntu/chunqian/MedLoRA/outputs/interns2_cpt1/adapter_model.safetensors`	只做额外文字知识预训练，种子 42

合并时传入**权重所在目录**，目录还应包含 `adapter_config.json`。每次选择一个最终补丁；B、C 的补丁已包含前面阶段的训练结果，无需逐个叠加。43 重训的是问答微调阶段，未重复知识预训练。

试用选择 / Trial choice

先试 A42，并与原版回答同一批题。选择 A 是为了用较简单的训练方案检查实际表现，不表示它在所有任务上最好。C 只有单种子结果；不能因为多一个训练阶段就认定更好。

`Intern-S2-Preview-MedLoRA` 是早期两数据集部署版，**不是本页的 A/B/C。**临时合并模型已清理，最终补丁保留；重新合并不等于重新训练。

执行前准备

Before deployment

运行位置：5090 主机，ubuntu 账号；命令使用 Bash。 不在 user0 容器运行，不在本机加载 35B。需先获得 0–3 号卡的可用时段，并约定归还时间；4–7 号卡不可用。停止原服务仅交给 `gpu_window.sh`。

1. 同步本次新增的 demo 模式（本机 Git Bash）

服务器是代码副本；旧脚本不认识 `STEPS=demo`。只同步这个文件，原子替换以免覆盖正在读取的旧文件。以下操作只同步代码，不启动模型。

```
cd '/c/Users/Y4/fyp/Topic 6/MedLoRA'
tar -czf trial-update.tar.gz scripts/server/gpu_window.sh
scp trial-update.tar.gz 5090:/home/ubuntu/chunqian/
ssh 5090 'cd /home/ubuntu/chunqian/MedLoRA &&
tar -xOf ../trial-update.tar.gz scripts/server/gpu_window.sh \
  > scripts/server/gpu_window.sh.next &&
bash -n scripts/server/gpu_window.sh.next &&
mv scripts/server/gpu_window.sh.next scripts/server/gpu_window.sh &&
sha256sum scripts/server/gpu_window.sh'
sha256sum scripts/server/gpu_window.sh
```

两边 SHA-256 应相同。连接失败即停，先处理连接问题。

2. 核对补丁、GPU 和磁盘（主机 Bash）

```
cd /home/ubuntu/chunqian/MedLoRA
ls -lh outputs/interns2_s2a/adapter_model.safetensors
cat outputs/interns2_s2a/adapter_config.json
nvidia-smi --query-gpu=index,memory.used,utilization.gpu \
  --format=csv -i 0,1,2,3
df -h / /home/share /home/ubuntu/chunqian/merged
readlink -f /home/ubuntu/chunqian/merged
```

合并目录所在盘需**至少 80 GB 可用空间**。若需临时借用 `/home/share`，每次都要重新获得管理员同意；之前的许可不自动延续。

3. 仅在已获准借盘且 merged 为空时设置临时位置

```
R=/home/ubuntu/chunqian
test -d "$R/merged" && test ! -L "$R/merged"
ls -A "$R/merged"                 # 必须为空
test ! -e /home/share/chunqian_tmp
mkdir -m 700 /home/share/chunqian_tmp
rmdir "$R/merged" && ln -s /home/share/chunqian_tmp "$R/merged"
```

逐步核对，任一步失败就停；已有目录或链接时先核实，不能自行删除。空间充足且不需借盘时，跳过第 3 步。

合并并限时启动

Merge and start a timed trial

1. 选模型与截止时间

下面以 A42 为例。截止时间使用**主机北京时间（UTC+8）**，必须改成已约定的未来时间，并留出至少 15 分钟。一次只启动一个模型。

```
cd /home/ubuntu/chunqian/MedLoRA
DEADLINE_AT='YYYY-MM-DD HH:MM'       # 替换为已约定时间
REPO=/home/ubuntu/chunqian/MedLoRA
TRIAL="exec env DEADLINE_AT='$DEADLINE_AT' MODELS=a STEPS=demo"
tmux new-session -d -s medlora_demo \
  "$TRIAL bash $REPO/scripts/server/gpu_window.sh"
tail -20 /home/ubuntu/chunqian/logs/gpu_window.log
```

`MODELS` 可选：`a` = A42，`a43` = A43，`b` = B42，`b43` = B43，`c` = C42，`cpt1` = 仅预训练。其他命令不变。

脚本先观察原服务两分钟；发现请求或 GPU 忙则退出。通过检查后停止原服务，合并指定补丁，启动试用服务。日志出现 **READY 人工试用** 后才开始提问。试用期间不会重新训练，也不会重跑整套评测。

A42 合并后的模型目录

```
/home/ubuntu/chunqian/merged/interns2_s2a
```

如 merged 指向已批准的临时盘，文件实际占用的是临时盘空间。脚本拒绝覆盖已有同名合并目录；不要为绕过检查自行删除旧文件。

2. 合并内部实际调用的命令（用于理解，不要重复运行）

```
bash train/interns2/run_sft35.sh merge a
PORT=23334 bash train/interns2/serve.sh start \
  /home/ubuntu/chunqian/merged/interns2_s2a
```

第一行在训练环境中加载原版基座和 A42 补丁，再保存完整模型；第二行通过 LMDeploy 使用 0–3 号卡启动接口。**人工试用应执行上面的时间窗命令**，由它统一负责启动、截止和恢复。

3. 结束与恢复

到点后自动结束试用，清理本次新建的临时合并模型，保留补丁，再启动原服务。合并或启动阶段每约 30 秒检查截止时间；恢复服务还需要启动时间。

需要提前结束时，在另一终端执行：

```
tmux send-keys -t medlora_demo C-c
tail -20 /home/ubuntu/chunqian/logs/gpu_window.log
```

等日志确认原服务已恢复，再交还使用时段。不要用强制杀进程或直接关闭整台机器的方式结束。恢复失败时查看日志并联系服务维护方。

提问与对比

Ask questions and compare answers

1. 在另一个主机 Bash 终端提问

```
cd /home/ubuntu/chunqian/MedLoRA
source /home/ubuntu/miniconda3/etc/profile.d/conda.sh
conda activate /home/ubuntu/chunqian/envs/s2train
python scripts/compare_ask.py ask \
  '请用三句话解释什么是气胸，不使用难懂的术语。'
python scripts/compare_ask.py ask \
  'Explain pneumothorax in three sentences using plain language.'
```

若 conda 安装在其他位置，按主机实际安装位置加载 `conda.sh`。工具每次先查询当前模型 ID，并在输出中标记模型。A42 应显示 `interns2_s2a`，A43 应显示 `interns2_s2a_s43`；显示其他版本时先核对。

接口为主机上的 `http://localhost:23334/v1`，提供 `/models` 和 `/chat/completions`。保持服务器内部访问；已有界面接入时，也必须按 `/models` 的实际返回值确认版本。请求关闭思考模式，`temperature=0`，与已有评测一致。

2. 看图提问

```
IMAGE=/absolute/path/to/public_image.png
python scripts/compare_ask.py ask \
  'Describe this image in two sentences. State uncertainty when needed.' \
  --image "$IMAGE"
```

将图片路径换成**获准使用的公开教学图片**。可用带标准答案的 SLAKE / VQA-RAD 测试图片；使用时保留样本编号和标准答案。不要使用受控胸片、私人病人资料或未经许可的数据。无图提问不能用来评价看图能力。

3. 固定题目，保存回答

将第 5–6 页题目保存为 UTF-8 的 `outputs/compare/trial_questions.jsonl`，一行一道题。例如：

```
{"id":"q01_zh","question":"请用三句话解释什么是气胸，不使用难懂的术语。"}
{"id":"q01_en","question":"Explain pneumothorax in three short sentences."}
```

```
mkdir -p outputs/compare
python scripts/compare_ask.py batch outputs/compare/trial_questions.jsonl \
  --out outputs/compare/trial_A42.jsonl
```

批量工具已有同 ID 回答会跳过。换题或改提示词时换一个输出文件，不把新旧回答混在一起。记录模型、完整问题、图片编号、回答和是否被截断。

与原版比较： 不能同时开两个 35B。先结束 A 的窗口并确认恢复；另约原版试用窗口，由服务维护方提供原版接口。使用同一题目文件和相同生成设置，保存到单独文件；工具可用 `--base <原版接口地址>` 指定接口。不能把早期两数据集版当作原版或 A。

试用能发现具体问题；几道例题不能代替准确率。 问答分数来自完整测试集。自由回答需有参考依据或专业复核，不能只因语气流畅就判为正确。

建议题目：文字问答

Suggested prompts: text questions

每组中英文分别提问，保持意思一致。这些是演示题，不是现有测试集的标准答案，也不保证训练时从未见过类似内容。观察点用于检查表达和推理，医学事实仍需可靠参考或专业复核。

Q1 • 概念解释 / Plain-language explanation

中文： 请用三句话解释什么是气胸，不使用难懂的术语。

English: Explain pneumothorax in three sentences using plain language.

观察： 是否回答所问、用词清楚、遵守三句话要求；内容是否经得起参考资料核对。

Q2 • 比较与格式 / Comparison and format

中文： 用三行表格比较 CT 和 MRI 的成像原理、是否使用电离辐射，以及一个常见用途。不要说其中一种在所有情况下都更好。

English: Use a three-row table to compare CT and MRI by imaging principle, use of ionizing radiation, and one common use. Do not claim that either is better in every situation.

观察： 三个方面是否都覆盖；是否按表格回答；是否把复杂差异说成绝对结论。

Q3 • 信息不足 / Recognizing insufficient information

中文： 虚构练习：一个人咳嗽、发热两天。仅凭这些信息能确定是肺炎吗？请说明还缺哪些信息，不要开药。

English: Fictional exercise: a person has had a cough and fever for two days. Is this information alone enough to confirm pneumonia? Explain what information is missing. Do not prescribe medication.

观察： 是否承认信息不足、区分可能性与确定诊断、遵守不提供处方的要求。

Q4 • 阅读证据 / Reading evidence

中文： 虚构练习：一项研究报告“服用 X 的人平均恢复更快”，但没有说明是否随机分组，也没有给出两组病情。仅凭这段话能证明 X 导致恢复更快吗？只回答“能”或“不能”，再用一句话说明原因。

English: Fictional exercise: a study says that people taking X recovered faster, but gives no information about randomization or baseline illness severity. Does this statement alone prove that X caused faster recovery? Answer “yes” or “no”, then explain in one sentence.

观察： 是否依照给定信息判断；是否避免编造样本数、疗效或不存在的研究细节；是否符合输出格式。

建议题目：图片与多轮

Suggested prompts: images and follow-up

Q5 • 图片短答 / Short visual answer

对同一张有标准答案的公开医学教学图片分别提问：

中文： 这张图片是什么影像检查类型？只回答检查类型；无法判断时回答“不确定”。

English: What imaging modality is shown? Answer with the modality only. If it cannot be determined, answer “uncertain”.

观察： 与该图片的标准答案核对，不能事先假定图片必然是 X 光或 CT。不要仅凭模型自信程度打分。

Q6 • 短答与描述一致性 / Consistency between answers and descriptions

选择获准使用、具有异常标注的公开胸片。以下两问分别附上**同一张图**，以独立请求提问；中英文各做一遍。

中文①： 这张胸片是否可见异常？只回答“是” “否”或“不确定”。

English ①: Is any abnormality visible in this chest X-ray? Answer only “yes”, “no”, or “uncertain”.

中文②： 请用两到三句话描述这张胸片，包括可见的异常；看不清或不能确定的地方请明确说明。

English ②: Describe this chest X-ray in two or three sentences, including visible abnormalities. Explicitly state anything that is unclear or uncertain.

观察： 是否一边回答“有异常”、一边又描述“完全正常”；是否遗漏标注中的异常；是否添加图中没有的异常。两个回答一致仍可能一起答错，必须结合标注复核。此处人工试问不能替代待完成的 CheXbert 复核。

Q7 • 多轮衔接 / Follow-up conversation

本组在支持对话历史的界面中测试；单独重复运行 `compare_ask.py ask` 不会保留上一轮。

中文①： 请用一句话解释“影像上的异常不一定等于已经确诊”。

中文②： 把刚才的解释改成更适合没有医学背景的人理解的说法，仍然只用一句话。

English ①: Explain in one sentence why an abnormal imaging finding does not by itself establish a diagnosis.

English ②: Rephrase your previous explanation for someone without a medical background, still using only one sentence.

观察： 是否记住上一轮内容、保留原意、按要求变得更易懂。界面需把两轮历史一并发送。

记录方式： 每题记录“符合 / 部分符合 / 不符合”，另标事实错误、漏答、矛盾、无依据细节或格式问题。少量试用记录只作定性比较，不能据此宣称临床可用。

结束检查与文件说明

Shutdown checks and reference files

1. 确认已恢复原服务

```
tail -30 /home/ubuntu/chunqian/logs/gpu_window.log
ss -ltn | grep -E ':2333[34] '
nvidia-smi --query-gpu=index,memory.used,utilization.gpu \
  --format=csv -i 0,1,2,3
```

正常结束后，日志应确认原服务已恢复，23333 应监听，试用服务 23334 应停止。原服务启动后重新占用 GPU 显存是预期行为。日志未确认恢复时不要直接离开。

2. 若本次借用了临时盘，核对后归还

demo 模式仅清理本次生成的完整模型，永久补丁不删。下列操作只用于本说明创建的临时链接，**先检查链接目标和目录为空**；不匹配就停止，不删除其他目录。

```
R=/home/ubuntu/chunqian
readlink "$R/merged"              # 应为 /home/share/chunqian_tmp
ls -A /home/share/chunqian_tmp      # 必须为空
if [ -L "$R/merged" ] &&
   [ "$(readlink "$R/merged")" = /home/share/chunqian_tmp ]; then
    if rmdir /home/share/chunqian_tmp; then
        unlink "$R/merged"
        mkdir "$R/merged"
    fi
fi
```

`rmdir` 只删除空目录；非空时保留现场并核实。测试回答文件保留在 `outputs/compare/`，不要把真实病人资料、受控图片或受控逐条记录带出服务器。

3. 本说明涉及的代码和记录

文件	用途
`scripts/server/gpu_window.sh`	本次新增 `STEPS=demo`，统一限时与恢复
`train/interns2/run_sft35.sh`	A/B/C 与 43 版本的映射、合并检查
`train/interns2/merge_lora.py`	基座与一个最终补丁合并
`train/interns2/serve.sh`	启动与停止本项目的模型服务
`scripts/compare_ask.py`	单题、图片题、批量提问与保存回答
`results/README.md`、`docs/report.md`	已完成的实验结果与解读

状态边界： 本说明根据本机代码与实验记录编写。未在服务器核对当前文件是否仍在、服务是否在线，也未实际执行新 demo 模式。部署前必须完成补丁、空间、脚本版本和使用时段检查。

使用范围： 用于研究演示和回答质量检查。现有分数不能证明任意医学问题都能正确回答；试用结果也不能代替专业判断。