35B 三步训练方案：知识预训练 → 问答微调 → 推理训练

- 负责人：Chunqian（Topic 6 / Task 1.3）
- 日期：2026-10-15 起草；2026-10-16 改为三步走（苏学长建议），第①步语料与数据已完成，第②③步按数据整理重新选定
- 状态：**方案，尚未开始**（等老师确认、等 0–3 号卡空出来）
- 相关：现有三个 35B 模型的训练细节见 `docs/TRAINING_35B.md`

一、代码在哪里

- GitHub：https://github.com/AugustLoo/MedLoRA
- 服务器（5090 主机，`ubuntu` 账号）：`/home/ubuntu/chunqian/MedLoRA`

用途	文件
35B LoRA 训练（自写，transformers + peft）	`train/interns2/train_lora.py`
补丁合并成完整模型	`train/interns2/merge_lora.py`
一条龙脚本（数据 → 冒烟 → 训练 → 合并 → 评测）	`train/interns2/run_6ds.sh`（S2-6datasets）、`train/interns2/run_cxp.sh`（S2-CheXpertPlus）
四模型对比服务（端口 23334）	`train/interns2/compare_serve.sh`
六个数据集的微调数据	`data/convert_sft6.py`（+ `convert_slake_sharegpt.py`、`convert_pubmedqa_sft.py`）
3B 时的预训练语料（参照）	`data/convert_pubmedqa_cpt.py`、`data/convert_iu_xray.py`、`data/convert_chexpert_b3.py`
评测	`eval/eval_slake.py`、`eval_pubmedqa.py`、`eval_general.py`（TextVQA）、`eval_mmbench.py`、`eval_medvqa.py`（VQA-RAD / PathVQA）、`eval_medqa.py`、`eval_pneumonia.py`、`eval_chexpert.py`、`chexbert_judge.py`
3B 预训练的配置（参照）	`configs/bf16/cpt_pubmed_qlora.yaml`、`cpt_iu_qlora.yaml`、`cpt_b3_top.yaml`、`cpt_b3_rand.yaml`、`sft_after_cpt*.yaml`
已训好的补丁（服务器）	`outputs/interns2_6ds/`、`outputs/interns2_cxp/`、`outputs/interns2_mix_300/`

二、LoRA 设置（和现有 35B 模型完全相同）

项目	设置
基座	Intern-S2-Preview（35B 混合专家，256 个路由专家、每个词激活 8 个，约 3B 激活）

项目	设置
方法	LoRA：rank 16，alpha 32（缩放 2），dropout 0.05
挂在哪里	语言模型的注意力层（全注意力 q/k/v/o、线性注意力 in_proj_qkv / in_proj_z / out_proj）+ 共享专家（gate / up / down），共 250 个线性层
可训练参数	19,169,280，占 **0.054%**
冻结	256 个路由专家（打包成 3D 参数）、路由器、视觉编码器、时间序列模块、词表
代码位置	`train_lora.py` 里的 `LORA_TARGETS["attn_shared"]`

三步都在**同一个 LoRA 补丁上接着训**，全程只训练 0.054% 的参数（题目里的「参数高效」），不用多合并模型。

三、三步的逻辑

```
原版 35B
   │  ① 知识预训练：医学教材 + 临床指南（纯文字，整段算损失）
   ▼
知识补丁 ──────────► 「只做预训练」模型（顺带评测）
   │  ② 问答微调：中文医学问答 / 对话 + 六个多模态看图问答数据集（只算回答的损失）
   ▼
问答补丁 ──────────► 模型 B
   │  ③ 推理训练：带解析的医学考题（中英文，先给答案再给解析）
   ▼
推理补丁 ──────────► 模型 C
```

步骤	类比人的学习	目的	属于论文题目的哪部分
① 知识预训练	读教材、看指南	先让模型有医学基本认知	增量预训练（Incremental Pretraining）
② 问答微调	跟诊、回答病人提问、看片子答题	学会按要求回答医学问题，包括看图答题	指令微调（Instruction Fine-Tuning）
③ 推理训练	做带解析的考题	学会解释、分析为什么	指令微调（带解释的指令数据）

为什么预训练只用纯文字：3B 上两次图文预训练（B2 IU X-Ray、B3 CheXpert Plus）都没帮上主任务，B2 只学会了报告写法；纯文字预训练（B1 PubMed）让纯文字医学题提高了 2.2 分。看图能力靠第②步的多模态数据练。

四、第①步：知识预训练语料（已定，2026-10-16 在 Hugging Face 上核实）

语料	内容	语言	全部规模	许可	本方案用多少
OpenMedText（`ywchoi/OpenMedText`）	29 本开源医学教材（解剖、生理、药理、细胞生物学、流行病学等）+ 12.1 万篇 MDPI 期刊文章	英文	教材全文 33.5 MB	期刊文章 CC BY 4.0；教材按本分 CC BY / BY-SA / BY-NC / BY-NC-SA	**29 本教材全部**（约 800 万 token）
MMedC（`Henrychur/MMedC`）	多语种医学语料；官方表格列了教材、过滤后的网页、医学网站、小数据集	8 种语言	255 亿 token；中文压缩包 4.6 GB，**实际只含网页语料（29 万篇，9.3 GB）和医学百科（7.58 万条，0.5 GB），没有教材**	CC BY-NC-SA 4.0	**医学百科抽样**（约 800 万 token）
Clinical Guidelines（`epfl-llm/guidelines`）	3.7 万篇临床诊疗指南（CCO、CDC、CMA、ICRC、NICE、PubMed、SPOR、WHO、WikiDoc），Meditron 训练语料的一部分	英文	878 MB	Common Crawl 使用条款	**抽样**（约 400 万 token）

- 合计约 2,000 万 token，切成最多 1,000 token 一段（训练截断 1,024），约 2.4 万段，1 轮。
- MMedC 的**英文教材没有包含**（官方说因为版权去掉了）；下载后发现**中文包里也没有教材文件夹**。所以英文知识来自 OpenMedText 教材和临床指南，中文知识来自 MMedC 的医学百科。
- **中文网页语料不用**：2026-10-16 抽 1,500 篇看过，一半以上是医院 SEO 推广页（例如「某某专科医院治鼾症手术费用」），关键词过滤分不开好坏。
- **百科也过滤推广条目**：推广用语（无痛人流、专科医院、咨询电话、免费名额等）每千字超过 2 次就跳过，抽样估计约 10%，多是公司简介、医生个人介绍和医院推广，正常的疾病条目基本不受影响。
- **验证集**：每个来源留约 1%（最多 100 段）。短篇整篇留出；教材这种长篇只留每本最后若干段，不会拿走一整本书。
- 三个语料都有非商用条款，本项目只做学术研究，论文里注明来源和许可证；处理后的数据不对外再分发。
- 下载：OpenMedText 很小，本机即可；MMedC 中文包 4.6 GB、指南 878 MB，尽量在服务器上直接下载，只解压教材部分（服务器硬盘约 88% 满）。
- 引用：MMedC — Qiu et al., *Towards Building Multilingual Language Model for Medicine*, arXiv 2402.13963；Guidelines — Chen et al., *MediTron-70B*, arXiv 2311.16079。
- 可选：混入 10–20% 通用文字一起训，减少遗忘（文献里最常用的做法）。

五、第②步：问答微调数据（2026-10-16 重新选定）

数据	全部规模	本方案用多少	类型	许可（数据卡）
HuatuoGPT-sft-data-v1（`FreedomIntelligence/HuatuoGPT-sft-data-v1`）	22.6 万条	抽 6,000	中文医学问答与对话，含多轮	Apache-2.0
DISC-Med-SFT（`Flmc/DISC-Med-SFT`）	约 46.5 万条	清洗后抽 6,000	中文问诊与多轮对话，基于医患对话和医学知识图谱重构	Apache-2.0
SLAKE	4,919	全部	看图问答	CC BY 4.0
PubMedQA（回放）	300	全部	是 / 否 / 不确定	MIT
VQA-RAD（已去掉问测试图的 1,059 题）	734	全部	看图问答	CC0
PathVQA	19,654	5,000	病理图问答	MIT
MedQA	10,178	3,000	医师考试四选一（英文）	MIT
PneumoniaMNIST	4,708	2,000	儿童胸片判断肺炎	CC BY 4.0

- 合计约 2.8 万条：中文问答 / 对话 1.2 万 + 六个多模态数据集 1.6 万（与 S2-6datasets 相同）。中文和多模态大致对半，免得看图能力被大量文字对话冲淡。
- 多模态的六个数据集**必须保留**：模型是多模态的，主要考试也是看图问答，第①③步都是纯文字。
- Huatuo26M-Lite 改为备选：HuatuoGPT-SFT 的对话更完整，两者都来自华佗团队，内容可能重叠。

不用的数据和原因

数据	原因
shibing624/medical（195 万条）	主要是华佗百科、华佗知识图谱和六科室问答的合并版，和上面重复
ChatMed_Consult_Dataset	回答由 GPT-3.5 生成，作者提醒有错误；许可说明前后矛盾（CC BY 与 CC BY-NC）
cMedQA2	限非商业研究，原本是「答案选择」任务，混有负样本
中文六科室问答（79 万对）	网络问答，广告和模板化回答多；需要时再按科室清洗后少量加入
PromptCBLUE	信息抽取、术语标准化等结构化任务，不是本课题的目标
UltraMedical	内含 MedQA、MedMCQA 原题，和本项目的 MedQA 测试集有重叠风险

六、第③步：推理训练数据（2026-10-16 重新选定）

数据	全部规模	本方案用多少	内容	许可
CMExam（`fzkuji/CMExam`，官方仓库 williamliujl/CMExam）	68,119 题（训练 54,497 / 验证 6,811 / 测试 6,811）	训练集抽 5,000	中国执业医师考试题，每题有答案和**解析**	Apache-2.0
MedMCQA（`openlifescienceai/medmcqa`）	训练 182,822 / 验证 4,183 / 测试 6,150	训练集中有解析的抽 5,000	印度医学考试选择题，带解析	Apache-2.0
medical-o1-reasoning-SFT（中文 `zh`、英文 `en` 子集）	英文纯医学约 2 万条	各抽 1,500，只用最终回答	GPT-4o 生成、经验证器检查的医学题解答	Apache-2.0

- **格式：不开思考模式，「先给答案，再给解析」。** 例如「答案：C\n解析：……」。理由：
  1. 评测和上线都关闭思考模式，训练也保持一致；
  2. 长推理链要把长度上限提到 2,048–4,096，35B 上显存和时间都吃紧；
  3. 第 3 周原版开思考，21% 的题在 4,096 token 内想不完，答完的题也只提高 1.8 分；
  4. CMExam、MedMCQA 的解析本来就短，medical-o1 只取最终回答（它本身就包含分析过程），不取冗长的推理链。
- 以后有时间，可以加一个开思考的小对照，作为论文的讨论点。
- 备选：Medical-R1-Distill-Data（英文 2.2 万 / 中文 1.7 万，DeepSeek-R1 推理链，Apache-2.0）、MedReason（3.3 万条，医学知识图谱推理，Apache-2.0）。两者以长推理链为主，暂不用。
- 生成的推理不等于医生的真实诊疗过程。抽查时分别看三点：最终答案对不对、解析是否支持答案、有没有无依据的医学结论。

七、数据质量检查（三步通用）

1. **跨数据集去重**：每条记录保留 `source`（来源数据集）和原始 ID，跨数据集去重，不只在每个文件内部去重。
2. **测试集隔离**：训练数据与所有评测集逐条比对（题干归一化后完全相同或高度相似就剔除），包括 SLAKE 中英文测试题、MedQA 测试集、PubMedQA 考卷半边、CMExam 验证 / 测试集、MedMCQA 验证集。medical-o1 的题目来自医学考试题库，尤其要查和 MedQA 测试集的重叠。
3. **清洗**：去掉广告、联系方式、身份证号这类个人信息，去掉问答主题对不上、回答过短或模板化的样本（沿用第①步的推广用语过滤）。
4. **抽检**：每个来源随机抽 50 条人工看一遍，记录问题比例。
5. **许可记录**：每个来源单独记录许可、版本和用途。MMedC（CC BY-NC-SA）、部分教材（BY-NC）只用于学术研究。

八、要比较的模型

模型	① 知识预训练	② 问答微调	③ 推理训练	回答的问题
原版	—	—	—	基线
S2-6datasets（已有）	—	只有六个多模态数据集	—	参考：没有中文问答时
A	—	✅	—	新对照组（第②步数据和 S2-6datasets 不同，要重训）
B	✅	✅	—	知识预训练有没有用（B 对比 A）
C	✅	✅	✅	推理训练有没有用（C 对比 B）
只做预训练	✅	—	—	顺带评测（第①步的产物）

一次只加一类数据，才能看出是哪一步带来了变化，而不是训完只得到一个说不清的总分。3B 上做过类似的预训练对比（B1 / B2 / B3：主任务都没有提升），两个规模可以互相印证。

九、训练设置

	① 知识预训练	② 问答微调	③ 推理训练
学习率	先短跑扫描 5e-5 / 1e-4 / 2e-4 再定	1e-4	5e-5（在②的基础上小步调整）
轮数	1	3	1
有效批大小	16	16	16
长度上限	1,024	1,024	1,024（只取答案 + 解析，不需要更长）
损失	整段文字	只算回答（多轮对话算每一轮回答）	只算答案 + 解析
图片	无	≤ 262,144 像素（512×512）	无
起点	原版	① 的补丁（A 从原版）	② 的补丁
随机种子	42	42	42

十、要改的代码

已完成（第①步，提交 c541eb1、c748d79）：

1. `train_lora.py` 加 `--mode pt`、`--init-adapter`、`--eval-data`；

2. `data/convert_cpt35_stage1.py`：第①步语料清洗、切段、抽样、留验证集；
3. `train/interns2/run_cpt35.sh`：data | smoke | sweep | train | status。

待做：

4. `train_lora.py` 支持**多轮对话**：现在只读第一轮问答，HuatuoGPT-SFT、DISC-Med-SFT 有多轮，每一轮回答都要算损失；
5. 第②步数据脚本：下载并清洗 HuatuoGPT-SFT、DISC-Med-SFT，抽样，与六个数据集合并，做第七节的去重和测试集隔离；
6. 第③步数据脚本：CMExam、MedMCQA、medical-o1 转成「答案 + 解析」格式；
7. 评测：`eval/eval_slake.py` 加 `--lang zh`；新增 CMExam 测试（抽 1,000 题，中文医师考试）；
8. 一条龙脚本：第②③步的 data | smoke | train | merge | eval。

十一、评测

- **A / B / C**：和 S2-6datasets 完全相同的一整套：SLAKE、PubMedQA、TextVQA、MMBench、VQA-RAD、PathVQA、MedQA、PneumoniaMNIST、CheXpert Plus 3,189 张成人胸片（漏报、误报、自相矛盾），再用 CheXbert 复核。
- **新加**：
  - SLAKE 中文测试题 1,033 道，看中文看图问答；
  - CMExam 测试集抽 1,000 题，看中文医学知识；
  - 去掉图像只给文字再测一次，证明模型真的在看图；
  - 关键指标给出置信区间。
- **只做预训练**：短答题分数会很低，这是正常的，重点看纯文字医学题。
- 考试分数只说明知识掌握，不代表能直接用于临床。

十二、时间和资源（估计）

步骤	估计
① 知识预训练（24,043 段 × 1 轮 ≈ 1,500 步）	约 2–3 小时，学习率扫描另加约 1 小时
② 问答微调（约 2.8 万条 × 3 轮 ≈ 5,200 步）	约 9–10 小时（A、B 各一次）
③ 推理训练（约 1.3 万条 × 1 轮 ≈ 800 步）	约 1.5–2 小时
合并（每个模型）	3–5 分钟
评测（每个模型）	约半天；A、B、C 共三个
CheXbert 复核（容器里只能用 CPU）	每个模型约 11 小时

- 显卡总共约 25 小时，用主机 0–3 号卡，训练前要和世龙协调暂停他的服务。

- 硬盘：一次只放得下一个合并好的模型（约 73 GB），要轮流合并、评测、删除；补丁（约 77 MB）永久保留。

十三、预期和风险

- 知识预训练可能和 3B 一样看不出提升。两个规模都没提升，本身就是有说服力的结论。
- 中文问答数据可能改善中文能力，但也可能冲淡英文和看图题，要看 A 和 S2-6datasets 的对比。
- 推理训练的提升预计主要在纯文字考题（MedQA、CMExam）上，看图题不一定变好；还要看「敢说不确定」和漏报有没有变差。
- 每个模型只训练一次。关键模型如果要写进论文，最好再用种子 43 训一次。
- 语料的非商用许可：仅限学术研究，论文中注明。