# 35B 三步训练方案：知识预训练 → 问答微调 → 推理训练

- 负责人：Chunqian（Topic 6 / Task 1.3）
- 日期：2026-10-15 起草；2026-10-16 改为三步走（苏学长建议），第①步语料与数据已完成，第②③步按数据整理重新选定
- 状态：**方案，尚未开始**（等老师确认、等 0–3 号卡空出来）
- 相关：现有三个 35B 模型的训练细节见 `docs/TRAINING_35B.md`

---

## 一、代码在哪里

- GitHub：https://github.com/AugustLoo/MedLoRA
- 服务器（5090 主机，`ubuntu` 账号）：`/home/ubuntu/chunqian/MedLoRA`

| 用途 | 文件 |
|---|---|
| 35B LoRA 训练（自写，transformers + peft） | `train/interns2/train_lora.py` |
| 补丁合并成完整模型 | `train/interns2/merge_lora.py` |
| 一条龙脚本（数据 → 冒烟 → 训练 → 合并 → 评测） | `train/interns2/run_6ds.sh`（S2-6datasets）、`train/interns2/run_cxp.sh`（S2-CheXpertPlus） |
| 四模型对比服务（端口 23334） | `train/interns2/compare_serve.sh` |
| 六个数据集的微调数据 | `data/convert_sft6.py`（+ `convert_slake_sharegpt.py`、`convert_pubmedqa_sft.py`） |
| 3B 时的预训练语料（参照） | `data/convert_pubmedqa_cpt.py`、`data/convert_iu_xray.py`、`data/convert_chexpert_b3.py` |
| 评测 | `eval/eval_slake.py`、`eval_pubmedqa.py`、`eval_general.py`（TextVQA）、`eval_mmbench.py`、`eval_medvqa.py`（VQA-RAD / PathVQA）、`eval_medqa.py`、`eval_pneumonia.py`、`eval_chexpert.py`、`chexbert_judge.py` |
| 3B 预训练的配置（参照） | `configs/bf16/cpt_pubmed_qlora.yaml`、`cpt_iu_qlora.yaml`、`cpt_b3_top.yaml`、`cpt_b3_rand.yaml`、`sft_after_cpt*.yaml` |
| 已训好的补丁（服务器） | `outputs/interns2_6ds/`、`outputs/interns2_cxp/`、`outputs/interns2_mix_300/` |

---

## 二、LoRA 设置（和现有 35B 模型完全相同）

| 项目 | 设置 |
|---|---|
| 基座 | Intern-S2-Preview（35B 混合专家，256 个路由专家、每个词激活 8 个，约 3B 激活） |

| 项目 | 设置 |
| --- | --- |
| 方法 | LoRA：rank 16，alpha 32（缩放 2），dropout 0.05 |
| 挂在哪里 | 语言模型的注意力层（全注意力 q/k/v/o、线性注意力 in_proj_qkv / in_proj_z / out_proj）+ 共享专家（gate / up / down），共 250 个线性层 |
| 可训练参数 | 19,169,280，占 **0.054%** |
| 冻结 | 256 个路由专家（打包成 3D 参数）、路由器、视觉编码器、时间序列模块、词表 |
| 代码位置 | `train_lora.py` 里的 `LORA_TARGETS["attn_shared"]` |

三步都在**同一个 LoRA 补丁上接着训**，全程只训练 0.054% 的参数（题目里的「参数高效」），不用多合并模型。

---

## 三、三步的逻辑

```
原版 35B
   │  ① 知识预训练：医学教材 + 临床指南（纯文字，整段算损失）
   ▼
知识补丁 ──────────► 「只做预训练」模型（顺带评测）
   │  ② 问答微调：中文医学问答 / 对话 + 六个多模态看图问答数据集（只算回答的损失）
   ▼
问答补丁 ──────────► 模型 B
   │  ③ 推理训练：带解析的医学考题（中英文，先给答案再给解析）
   ▼
推理补丁 ──────────► 模型 C
```

| 步骤 | 类比人的学习 | 目的 | 属于论文题目的哪部分 |
| --- | --- | --- | --- |
| ① 知识预训练 | 读教材、看指南 | 先让模型有医学基本认知 | 增量预训练（Incremental Pretraining） |
| ② 问答微调 | 跟诊、回答病人提问、看片子答题 | 学会按要求回答医学问题，包括看图答题 | 指令微调（Instruction Fine-Tuning） |
| ③ 推理训练 | 做带解析的考题 | 学会解释、分析为什么 | 指令微调（带解释的指令数据） |

为什么预训练只用纯文字：3B 上两次图文预训练（B2 IU X-Ray、B3 CheXpert Plus）都没帮上主任务，B2 只学会了报告写法；纯文字预训练（B1 PubMed）让纯文字医学题提高了 2.2 分。看图能力靠第②步的多模态数据练。

---

## 四、第①步：知识预训练语料（已定，2026-10-16 在 Hugging Face 上核实）

| 语料 | 内容 | 语言 | 全部规模 | 许可 | 本方案用多少 |
|---|---|---|---|---|---|
| **OpenMedText**（`ywchoi/OpenMedText`） | 29 本开源医学教材（解剖、生理、药理、细胞生物学、流行病学等）+ 12.1 万篇 MDPI 期刊文章 | 英文 | 教材全文 33.5 MB | 期刊文章 CC BY 4.0；教材按本分 CC BY / BY-SA / BY-NC / BY-NC-SA | **29 本教材全部**（约 800 万 token） |
| **MMedC**（`Henrychur/MMedC`） | 多语种医学语料；官方表格列了教材、过滤后的网页、医学网站、小数据集 | 8 种语言 | 255 亿 token；中文压缩包 4.6 GB，**实际只含网页语料（29 万篇，9.3 GB）和医学百科（7.58 万条，0.5 GB），没有教材** | CC BY-NC-SA 4.0 | **医学百科抽样**（约 800 万 token） |
| **Clinical Guidelines**（`epfl-llm/guidelines`） | 3.7 万篇临床诊疗指南（CCO、CDC、CMA、ICRC、NICE、PubMed、SPOR、WHO、WikiDoc），Meditron 训练语料的一部分 | 英文 | 878 MB | Common Crawl 使用条款 | **抽样**（约 400 万 token） |

- 合计约 2,000 万 token，切成最多 1,000 token 一段（训练截断 1,024），约 2.4 万段，1 轮。
- MMedC 的**英文教材没有包含**（官方说因为版权去掉了）；下载后发现**中文包里也没有教材文件夹**。所以英文知识来自 OpenMedText 教材和临床指南，中文知识来自 MMedC 的医学百科。
- **中文网页语料不用**：2026-10-16 抽 1,500 篇看过，一半以上是医院 SEO 推广页（例如「某某专科医院治鼾症手术费用」），关键词过滤分不开好坏。
- **百科也过滤推广条目**：推广用语（无痛人流、专科医院、咨询电话、免费名额等）每千字超过 2 次就跳过，抽样估计约 10%，多是公司简介、医生个人介绍和医院推广，正常的疾病条目基本不受影响。
- **验证集**：每个来源留约 1%（最多 100 段）。短篇整篇留出；教材这种长篇只留每本最后若干段，不会拿走一整本书。
- 三个语料都有非商用条款，本项目只做学术研究，论文里注明来源和许可证；处理后的数据不对外再分发。
- 下载：OpenMedText 很小，本机即可；MMedC 中文包 4.6 GB、指南 878 MB，尽量在服务器上直接下载，只解压教材部分（服务器硬盘约 88% 满）。
- 引用：MMedC — Qiu et al., *Towards Building Multilingual Language Model for Medicine*, arXiv 2402.13963；Guidelines — Chen et al., *MediTron-70B*, arXiv 2311.16079。
- 可选：混入 10–20% 通用文字一起训，减少遗忘（文献里最常用的做法）。

---

## 五、第②步：问答微调数据（2026-10-16 重新选定）

| 数据 | 全部规模 | 本方案用多少 | 类型 | 许可（数据卡） |
|---|---|---|---|---|
| **HuatuoGPT-sft-data-v1**（`FreedomIntelligence/HuatuoGPT-sft-data-v1`） | 22.6 万条 | 抽 6,000 | 中文医学问答与对话，含多轮 | Apache-2.0 |
| **DISC-Med-SFT**（`Flmc/DISC-Med-SFT`） | 约 46.5 万条 | 清洗后抽 6,000 | 中文问诊与多轮对话，基于医患对话和医学知识图谱重构 | Apache-2.0 |
| SLAKE | 4,919 | 全部 | 看图问答 | CC BY 4.0 |
| PubMedQA（回放） | 300 | 全部 | 是 / 否 / 不确定 | MIT |
| VQA-RAD（已去掉问测试图的 1,059 题） | 734 | 全部 | 看图问答 | CC0 |
| PathVQA | 19,654 | 5,000 | 病理图问答 | MIT |
| MedQA | 10,178 | 3,000 | 医师考试四选一（英文） | MIT |
| PneumoniaMNIST | 4,708 | 2,000 | 儿童胸片判断肺炎 | CC BY 4.0 |

- 合计约 2.8 万条：中文问答 / 对话 1.2 万 + 六个多模态数据集 1.6 万（与 S2-6datasets 相同）。中文和多模态大致对半，免得看图能力被大量文字对话冲淡。
- 多模态的六个数据集**必须保留**：模型是多模态的，主要考试也是看图问答，第①③步都是纯文字。
- Huatuo26M-Lite 改为备选：HuatuoGPT-SFT 的对话更完整，两者都来自华佗团队，内容可能重叠。

**不用的数据和原因**

| 数据 | 原因 |
|---|---|
| shibing624/medical（195 万条） | 主要是华佗百科、华佗知识图谱和六科室问答的合并版，和上面重复 |
| ChatMed_Consult_Dataset | 回答由 GPT-3.5 生成，作者提醒有错误；许可说明前后矛盾（CC BY 与 CC BY-NC） |
| cMedQA2 | 限非商业研究，原本是「答案选择」任务，混有负样本 |
| 中文六科室问答（79 万对） | 网络问答，广告和模板化回答多；需要时再按科室清洗后少量加入 |
| PromptCBLUE | 信息抽取、术语标准化等结构化任务，不是本课题的目标 |
| UltraMedical | 内含 MedQA、MedMCQA 原题，和本项目的 MedQA 测试集有重叠风险 |

---

## 六、第③步：推理训练数据（2026-10-16 重新选定）

| 数据 | 全部规模 | 本方案用多少 | 内容 | 许可 |
|---|---|---|---|---|
| **CMExam**（`fzkuji/CMExam`，官方仓库 williamliujl/CMExam） | 68,119 题（训练 54,497 / 验证 6,811 / 测试 6,811） | 训练集抽 5,000 | 中国执业医师考试题，每题有答案和**解析** | Apache-2.0 |
| **MedMCQA**（`openlifescienceai/medmcqa`） | 训练 182,822 / 验证 4,183 / 测试 6,150 | 训练集中有解析的抽 5,000 | 印度医学考试选择题，带解析 | Apache-2.0 |
| **medical-o1-reasoning-SFT**（中文 `zh`、英文 `en` 子集） | 英文纯医学约 2 万条 | 各抽 1,500，只用最终回答 | GPT-4o 生成、经验证器检查的医学题解答 | Apache-2.0 |

- **格式：不开思考模式，「先给答案，再给解析」。** 例如「答案：C\n解析：……」。理由：
  1. 评测和上线都关闭思考模式，训练也保持一致；
  2. 长推理链要把长度上限提到 2,048–4,096，35B 上显存和时间都吃紧；
  3. 第 3 周原版开思考，21% 的题在 4,096 token 内想不完，答完的题也只提高 1.8 分；
  4. CMExam、MedMCQA 的解析本来就短，medical-o1 只取最终回答（它本身就包含分析过程），不取冗长的推理链。
- 以后有时间，可以加一个开思考的小对照，作为论文的讨论点。
- 备选：Medical-R1-Distill-Data（英文 2.2 万 / 中文 1.7 万，DeepSeek-R1 推理链，Apache-2.0）、MedReason（3.3 万条，医学知识图谱推理，Apache-2.0）。两者以长推理链为主，暂不用。
- 生成的推理不等于医生的真实诊疗过程。抽查时分别看三点：最终答案对不对、解析是否支持答案、有没有无依据的医学结论。

---

## 七、数据质量检查（三步通用）

1. **跨数据集去重**：每条记录保留 `source`（来源数据集）和原始 ID，跨数据集去重，不只在每个文件内部去重。
2. **测试集隔离**：训练数据与所有评测集逐条比对（题干归一化后完全相同或高度相似就剔除），包括 SLAKE 中英文测试题、MedQA 测试集、PubMedQA 考卷半边、CMExam 验证 / 测试集、MedMCQA 验证集。medical-o1 的题目来自医学考试题库，尤其要查和 MedQA 测试集的重叠。
3. **清洗**：去掉广告、联系方式、身份证号这类个人信息，去掉问答主题对不上、回答过短或模板化的样本（沿用第①步的推广用语过滤）。
4. **抽检**：每个来源随机抽 50 条人工看一遍，记录问题比例。
5. **许可记录**：每个来源单独记录许可、版本和用途。MMedC（CC BY-NC-SA）、部分教材（BY-NC）只用于学术研究。

---

## 八、要比较的模型

| 模型 | ① 知识预训练 | ② 问答微调 | ③ 推理训练 | 回答的问题 |
|---|---|---|---|---|
| 原版 | — | — | — | 基线 |
| S2-6datasets（已有） | — | 只有六个多模态数据集 | — | 参考：没有中文问答时 |
| **A** | — | ✅ | — | 新对照组（第②步数据和 S2-6datasets 不同，要重训） |
| **B** | ✅ | ✅ | — | 知识预训练有没有用（B 对比 A） |
| **C** | ✅ | ✅ | ✅ | 推理训练有没有用（C 对比 B） |
| 只做预训练 | ✅ | — | — | 顺带评测（第①步的产物） |

一次只加一类数据，才能看出是哪一步带来了变化，而不是训完只得到一个说不清的总分。3B 上做过类似的预训练对比（B1 / B2 / B3：主任务都没有提升），两个规模可以互相印证。

---

## 九、训练设置

| | ① 知识预训练 | ② 问答微调 | ③ 推理训练 |
|---|---|---|---|
| 学习率 | 先短跑扫描 5e-5 / 1e-4 / 2e-4 再定 | 1e-4 | 5e-5（在②的基础上小步调整） |
| 轮数 | 1 | 3 | 1 |
| 有效批大小 | 16 | 16 | 16 |
| 长度上限 | 1,024 | 1,024 | 1,024（只取答案 + 解析，不需要更长） |
| 损失 | 整段文字 | 只算回答（多轮对话算每一轮回答） | 只算答案 + 解析 |
| 图片 | 无 | ≤ 262,144 像素（512×512） | 无 |
| 起点 | 原版 | ① 的补丁（A 从原版） | ② 的补丁 |
| 随机种子 | 42 | 42 | 42 |

---

## 十、代码与数据（2026-10-16 全部完成，GPU 冒烟测试已通过；训练记录见第十四节）

| 内容 | 文件 | 说明 |
|---|---|---|
| 训练 | `train/interns2/train_lora.py` | `--mode pt` 纯文字预训练；`--init-adapter` 从上一步补丁接着训；`--eval-data` 验证损失；**多轮对话**每一轮回答都算损失（用 35B 真实模板核对过） |
| 第①步数据 | `data/convert_cpt35_stage1.py` | 教材 + 指南 + 中文百科，切段、抽样、留验证集 |
| 第②步数据 | `data/convert_sft35_stage2.py` | HuatuoGPT-SFT + DISC-Med-SFT 清洗、去重、测试集隔离、抽样 |
| 第③步数据 | `data/convert_sft35_stage3.py` | CMExam、MedMCQA、medical-o1 转成「答案 + 解析」 |
| 共用 | `data/sft35_common.py` | 测试集隔离索引（所有评测题的 20 字窗口）、个人信息 / 推广 / 网页残留清洗 |
| 评测 | `eval/eval_slake.py --lang zh`、`eval/eval_cmexam.py` | SLAKE 中文题（按「是 / 否」归一、按字判分）；CMExam 测试集抽 1,000 道单选 |
| 一条龙 | `train/interns2/run_cpt35.sh`、`train/interns2/run_sft35.sh` | ①：data / smoke / sweep / train；②③：data2 / data3 / smoke / train a·b·c / merge / eval / evalzh |
| 测试 | `tests/test_convert_cpt35_stage1.py`、`tests/test_sft35_data.py`、`tests/test_train_lora_pt.py` | 共 34 个，服务器上全部通过 |

**服务器上已生成的数据**（`/home/ubuntu/chunqian/data/processed/`）：

| 文件 | 内容 |
|---|---|
| `cpt35_stage1.json` / `_val.json` | 第①步：训练 24,043 段 + 验证 235 段，1,937 万 token |
| `sft35_zh_dialog.json` | 第②步中文：华佗 6,000（1–3 轮）+ DISC 6,000（医患对话 5,222、知识图谱问答 778），共 12,000 |
| `sft35_reasoning.json` | 第③步：CMExam 5,000 + MedMCQA 5,000 + medical-o1 中文 1,500 + 英文 1,500，共 13,000 |

清洗与隔离的结果（详见同目录 `*_stats.json`）：

- DISC 的 cMedQA 部分 2 万条整体排除；提到图片但没有图的对话丢掉 430 条；
- 测试集隔离：CMExam 训练集里有 211 道与它自己的验证 / 测试集重复或改写（查过的约 5%），MedMCQA 117 道，medical-o1 8 道，都已剔除；

- 推广过滤：问答数据改用更严的规则（两种以上「我院 / 热线 / 在线咨询……」才算），第一版沿用第①步规则时误伤了约四成正常问答；
- 所有样本套上模板后都不超过 1,024 token（最长 945）。

## 十一、评测

- **A / B / C**：和 S2-6datasets 完全相同的一整套：SLAKE、PubMedQA、TextVQA、MMBench、VQA-RAD、PathVQA、MedQA、PneumoniaMNIST、CheXpert Plus 3,189 张成人胸片（漏报、误报、自相矛盾），再用 CheXbert 复核。
- **新加**：
  - SLAKE 中文测试题 1,033 道，看中文看图问答；
  - CMExam 测试集抽 1,000 题，看中文医学知识；
  - 去掉图像只给文字再测一次，证明模型真的在看图；
  - 关键指标给出置信区间。
- **只做预训练**：短答题分数会很低，这是正常的，重点看纯文字医学题。
- 考试分数只说明知识掌握，不代表能直接用于临床。

---

## 十二、时间和资源（估计）

| 步骤 | 估计 |
| --- | --- |
| ① 知识预训练（24,043 段 × 1 轮 ≈ 1,500 步） | 约 2–3 小时，学习率扫描另加约 1 小时 |
| ② 问答微调（约 2.8 万条 × 3 轮 ≈ 5,200 步） | 约 9–10 小时（A、B 各一次） |
| ③ 推理训练（约 1.3 万条 × 1 轮 ≈ 800 步） | 约 1.5–2 小时 |
| 合并（每个模型） | 3–5 分钟 |
| 评测（每个模型） | 约 3 小时显卡（主机约 2 小时 + 容器里 CheXpert Plus 约 1 小时，按 S2-6datasets 的实际用时）；A、B、C 共约 9 小时，加上只做①的约 12 小时 |
| CheXbert 复核（容器里只能用 CPU） | 每个模型约 11 小时 |

- 显卡总共约 25 小时，用主机 0–3 号卡，训练前要和世龙协调暂停他的服务。
- 硬盘：一次只放得下一个合并好的模型（约 73 GB），要轮流合并、评测、删除；补丁（约 77 MB）永久保留。

---

## 十三、预期和风险

- 知识预训练可能和 3B 一样看不出提升。两个规模都没提升，本身就是有说服力的结论。
- 中文问答数据可能改善中文能力，但也可能冲淡英文和看图题，要看 A 和 S2-6datasets 的对比。
- 推理训练的提升预计主要在纯文字考题（MedQA、CMExam）上，看图题不一定变好；还要看「敢说不确定」和漏报有没有变差。
- 每个模型只训练一次。关键模型如果要写进论文，最好再用种子 43 训一次。
- 语料的非商用许可：仅限学术研究，论文中注明。

---

## 十四、训练记录（2026-10-16 至 10-18，评测待做）

四个补丁都训完了，在主机 `/home/ubuntu/chunqian/MedLoRA/outputs/<标签>/`。训练记录快照：`results/interns2_3stage_train_2026-10-18.json`。

| | ① 只做预训练 | A：只做② | B：①→② | C：①→②→③ |
|---|---|---|---|---|
| 标签 | `interns2_cpt1` | `interns2_s2a` | `interns2_s2b` | `interns2_s3c` |
| 起点 | 原版 | 原版 | ① 的补丁 | B 的补丁 |
| 数据 | 教材 + 指南 + 百科 24,043 段（1,937 万 token） | 六个多模态数据集 15,953 + 中文对话 12,000 = 27,953 条 | 同 A | 带解析的考题 13,000 条 |
| 学习率 / 轮数 | 1e-4 / 1 | 1e-4 / 3 | 1e-4 / 3 | 5e-5 / 1 |
| 步数 | 1,502 | 5,241 | 5,241 | 812 |
| 用时 | 3.1 小时 | 约 9.5 小时（含一次崩溃后续训） | 9.0 小时 | 1.4 小时 |
| 训练损失（前 10% → 后 10% 平均） | 1.705 → 1.628 | 1.409 → 1.255 | 1.399 → 1.252 | 1.253 → 1.202 |
| 验证损失（235 段留出的教材 / 指南 / 百科） | 1.735 → 1.596 | — | — | — |

**第①步的学习率扫描**（各跑 120 步，看留出段的验证损失）：

| 学习率 | 第 0 步 | 第 60 步 | 第 120 步 |
|---|---|---|---|
| 5e-5 | 1.735 | 1.690 | 1.684 |
| **1e-4（选用）** | 1.735 | 1.677 | 1.667 |
| 2e-4 | 1.735 | 1.662 | 1.654 |

规则事先定好：取「在最好值 1% 以内的最小学习率」。2e-4 只比 1e-4 低 0.8%，按规则选 1e-4（步子小一些，对原有能力更稳）。 正式训练的验证损失一路下降、后期变平（1.735 → 1.635（200 步）→ 1.602（800 步）→ 1.596），没有过拟合迹象。

**几点观察（不是评测结论）**：

- A 和 B 的训练损失几乎一样（后 10% 平均 1.255 对 1.252）。B 开头低一点（1.40 对 1.41），说明第①步的补丁对第②步的数据有一点帮助，但很快就被追平。有没有用要看评测。
- C 的损失从 1.25 降到 1.20，推理题的答案（含解析）比短答长得多，损失本来就不会降到很低。

**训练中修好的一个问题（模型 A 第 1,745 步崩溃）**：

- 现象：`apply_rotary_pos_emb` 报张量尺寸不匹配。
- 原因：35B 的模型会缓存上一个带图批次的位置偏移（`rope_deltas`），遇到纯文字批次时按「批大小 ÷ 缓存大小」复用。第一轮最后一批只剩 1 条纯文字，前一批是 4 条带图，1 ÷ 4 = 0，得到空张量。这是第一次在训练里混入纯文字多轮对话才暴露出来的。
- 修法：每次前向之前把缓存清掉（`reset_rope_cache`，训练和验证都清），单元测试覆盖（提交 3c52642）。从第 1,700 步的断点接着训完。
- 以前的模型不受影响：它们每批都有图，或者偏移在同一条序列内是常数。

**和世龙的服务协调**：①、A、B、C 都在世龙同意的时段里跑，链式脚本退出时自动恢复他的服务（10-18 10:18 已恢复）。

**还没做**：

- A / B / C（和只做预训练的①）的评测：每个模型合并约 73 GB，一次一个；每个约 3 小时显卡（主机约 2 小时 + 容器 CheXpert Plus 约 1 小时），四个共约 12 小时；CheXbert 复核只用容器 CPU，每个 11–28 小时；
- 关键模型用种子 43 再训一次。